[PORTADA]

Evaluación de rendimiento de la arquitectura transformer frente a clasificadores lineales en la detección de desinformación política en español.

Defensa de Pruebas de Concepto (PoC)

Wilman Alejandro Morocho Carrión

NotebookLM

Detección de Desinformación Política

La propagación de noticias falsas en español requiere sistemas de detección automática rápidos y precisos.

Modelos Lineales (SVM, Regresión Logística)

Enfoque tradicional, alta eficiencia.

Deep Learning (Transformer BETO)

Estado del arte, alta comprensión contextual.

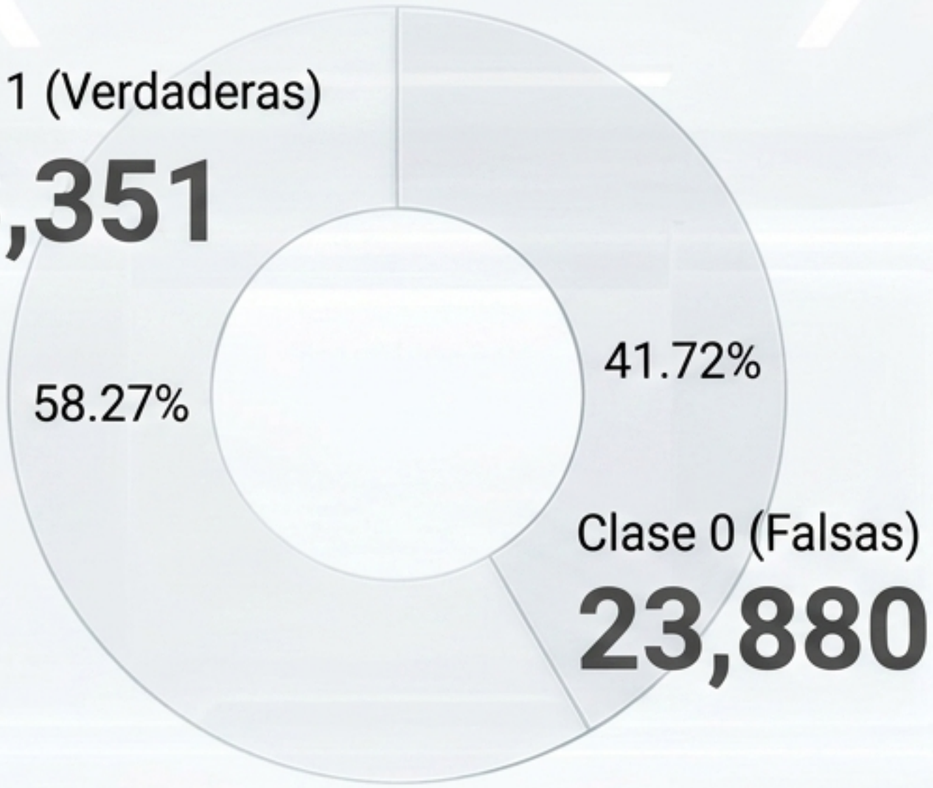
Objetivo: Determinar el balance óptimo (trade-off) entre **precisión predictiva** y **costo computacional**, asegurando la reproducibilidad técnica del experimento.

NotebookLM

Corpus Total

57,231

noticias políticas



Longitud Promedio

Titulares:
16 palabras

Descripciones:
38 palabras

Riesgo de Desbalance

Propensión a sesgar el modelo hacia la clase mayoritaria (Clase 1). Requiere mitigación en la fase de entrenamiento. La presencia de ruido (URLs, menciones) exige limpieza técnica.

NotebookLM



SVM / Regresión Logística	Transformer (BETO cased)
Objetivo: Reducción de dimensionalidad para evitar matrices TF-IDF dispersas.	**Objetivo:** Preservación del contexto para atención bidireccional.
Minúsculas: Sí (Normalización total).	**Minúsculas:** No (Diferencia GOBIERNO de gobierno).
Puntuación: Eliminada (Limpieza RegEx profunda).	**Puntuación:** Mantenida (Estructura gramatical intacta).
Stop Words: Eliminadas (Vía NLTK).	**Stop Words:** Mantenidas.
Stemming: Aplicado (Snowball - reducción a raíz morfológica).	**Stemming:** No aplicado (Solo se remueven URLs y menciones).

NotebookLM

Corpus Total

57,231

registros.

80 / 20

Corpus de Desarrollo

80% (45,784 registros).

Validación Cruzada

Stratified 5-Fold CV.

Test Blind Set (Conjunto Ciego)

20% (11,447 registros)

Aislado completamente para evaluación final.

- **Estrategia de Balanceo:** Uso de RandomUnderSampler. Aplicado exclusivamente en los pliegues de entrenamiento durante cada iteración para evitar fuga de datos.
- **Vectorización:** TF-IDF demostró superioridad frente a Word2Vec (CBOW/Skip-gram) para la rama lineal.

NotebookLM

[RESULTADOS CV] | Entrenamiento Lineal

SVM - LinearSVC

F1-Score (CV)

0.9035

Tiempo:	**2.81 min**
RAM:	**2.59 GB**

Configuración: TF-IDF óptimo (hasta 20,000 características). Solucionador LIBLINEAR.

Regresión Logística

F1-Score (CV)

0.9041

Tiempo:	**1.34 min**
RAM:	**2.56 GB**

Configuración: Solucionador liblinear.

Nota: El entrenamiento se ejecutó sobre 45,784 registros mediante GridSearchCV (60 ajustes totales por algoritmo).

NotebookLM

[RESULTADOS CV] | Entrenamiento BETO (Fine-Tuning)

Especificaciones Técnicas

- **Hardware:** GPU NVIDIA T4 (CUDA 13.0).
- **Base:** bert-base-spanish-wwm-cased
- **Hiperparámetros:** Batch size: 16 | Max tokens: 128 | LR: 2e-5 | 3 épocas por fold.

F1-Score Promedio

0.9697

(Dev. Est: 0.002)

Tiempo Total

63.5 minutos (~12.6 min/fold)

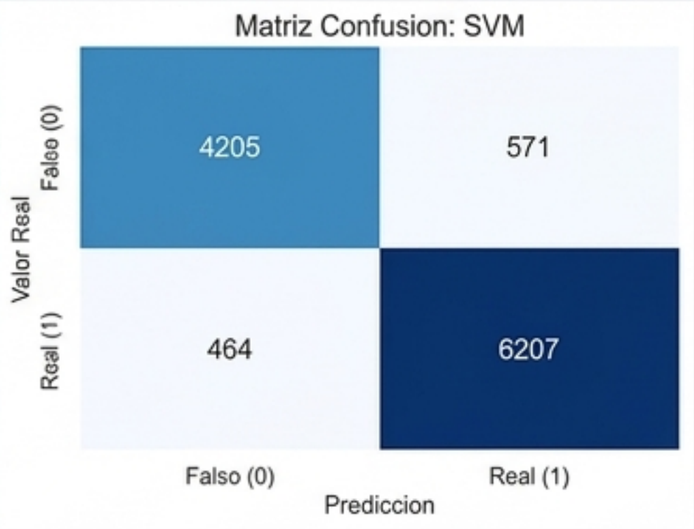
Memoria

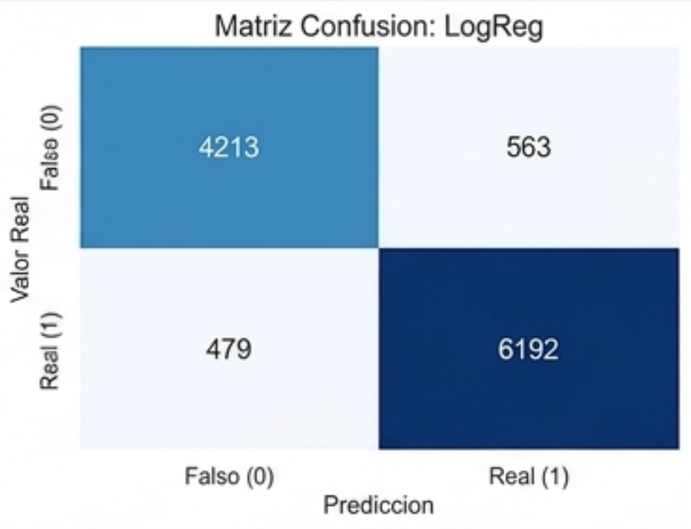
2.24 GB de VRAM pico

Nota: Entrenamiento final de exportación realizado sobre 38,208 muestras perfectamente balanceadas (19,104 Verdaderas / 19,104 Falsas).

NotebookLM

[EVALUACIÓN FINAL] | Conjunto Ciego - Modelos Lineales






```
============================================================
 REPORTE DE CLASIFICACION (HOLD-OUT) - SVM (LinearSVC)
============================================================
              precision    recall  f1-score   support

       Falso       0.90      0.88      0.89      4776
        Real       0.92      0.93      0.92      6671

    accuracy                           0.91     11447
   macro avg       0.91      0.91      0.91     11447
weighted avg       0.91      0.91      0.91     11447


============================================================
 REPORTE DE CLASIFICACION (HOLD-OUT) - REGRESION LOGISTICA
============================================================
              precision    recall  f1-score   support

       Falso       0.90      0.88      0.89      4776
        Real       0.92      0.93      0.92      6671

    accuracy                           0.91     11447
   macro avg       0.91      0.91      0.91     11447
weighted avg       0.91      0.91      0.91     11447
```

Métricas Consolidadas

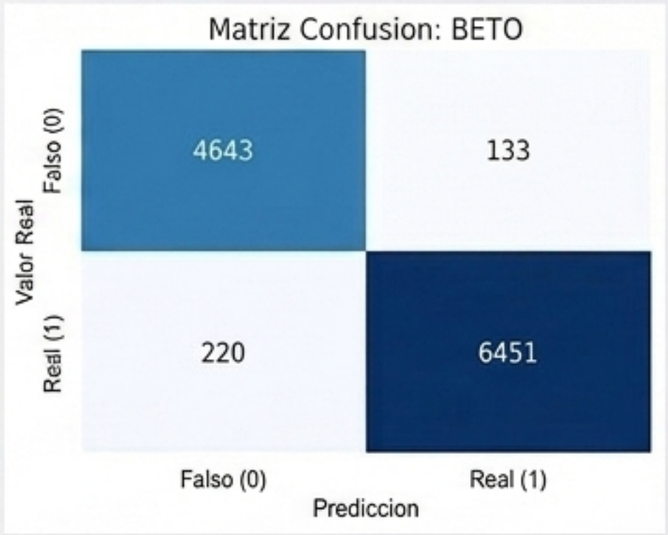
Test Set: 11,447 registros

- **F1-Score Macro:**
  - SVM: 0.9067
  - LogReg: 0.9062
- **Costo de Inferencia:** ~3.5 segundos de ejecución total.
- **Uso de Memoria:** ~63 MB RAM adicional.

Despliegue ultraligero (CPU)

NotebookLM

[EVALUACIÓN FINAL] | Conjunto Ciego - Modelo BETO




```
============================================================
 REPORTE DE CLASIFICACION (HOLD-OUT) - BETO
============================================================
              precision    recall  f1-score   support

       Falso       0.95      0.97      0.96      4776
        Real       0.98      0.97      0.97      6671

    accuracy                           0.97     11447
   macro avg       0.97      0.97      0.97     11447
weighted avg       0.97      0.97      0.97     11447
```

Métricas Consolidadas

Test Set: 11,447 registros

- **F1-Score Macro:** 0.9684
- **Incremento:** +6.2% vs. Modelos Lineales.
- **Costo de Inferencia:** 85.00 segundos (24x más lento).
- **Uso de Memoria:** 561.25 MB de VRAM requerida.

Requiere aceleración GPU (T4)

NotebookLM

[DISCUSIÓN] | Análisis del Trade-Off (Rendimiento vs. Costo)

Eficiencia (Lineales)

F1 >90% | Inferencia: 3s | CPU

Altamente competitivos. Desempeño excepcional para tareas de NLP con restricciones severas de hardware y presupuesto.

Vanguardia (Transformer)

F1 ~97% | Inferencia: 85s | GPU (VRAM)

Estado del arte. Precisión superior apalancada por la atención bidireccional, pero exige infraestructura especializada (24x más lento en inferencia).



La elección del algoritmo trasciende la precisión aislada; es una función de la métrica (F1) ponderada por los recursos de despliegue objetivo.

NotebookLM

[CONCLUSIONES] | Hallazgos Técnicos

1. **Sinergia Arquitectura-Preprocesamiento:** La limpieza de datos no es universal. El aprendizaje profundo penaliza la pérdida de estructura gramatical, mientras que los modelos lineales exigen reducción de dimensionalidad.

2. **Competitividad Lineal:** SVM y Regresión Logística mantienen una vigencia excepcional, superando la barrera del 90.6% de F1 con una fracción ínfima de recursos computacionales.

3. **Superioridad del Transformer:** El F1-Score de 96.84% valida empíricamente la capacidad de la arquitectura BETO para capturar sutilezas semánticas en el discurso de la desinformación política.

4. **Decisión Basada en Contexto:** La PoC demuestra que no existe un modelo perfecto. La implementación óptima dependerá de la capacidad de infraestructura del entorno de producción.

NotebookLM